ESCUELA POLITÉCNICA NACIONAL

F_AA_234A

VICERRECTORADO DE DOCENCIA

PLAN DE TRABAJO DE INTEGRACIÓN CURRICULAR

I. INFORMACIÓN BÁSICA	
Unidad Académica:	Facultad de Ingeniería de Sistemas
Carrera:	Ingeniería de Software
Proyecto:	Optimización y estudio longitudinal de modelos de Reconocimiento de Gestos de la Mano (HGR) que usan señales Electromiográficas de Superficie (sEMG).
Componente:	Optimización, entrenamiento y análisis longitudinal de modelos tradicionales de reconocimiento de gestos de la mano (kNN, SVM, ANN) usando señales electromiográficas de superficie (sEMG).
Línea de investigación:	Ciencias de la Computación e Inteligencia Artificial
Nombres y apellidos del estudiante:	Álvarez Zambrano Alejandro Sebastián
Nombres y apellidos del Profesor:	Ángel Leonardo Valdivieso Caraguay

II. DESCRIPCIÓN DEL COMPONENTE

El reconocimiento de gestos de la mano (*Hand Gesture Recognition*, HGR) es una tecnología que permite a una máquina identificar e interpretar los movimientos de la mano humana. Una de las formas más prometedoras para lograrlo es mediante el uso de señales electromiográficas de superficie (*surface Electromyography*, sEMG), una técnica no invasiva que registra la actividad eléctrica generada por los músculos durante su contracción (Barona-Lopez et al., 2021). La principal aplicación de esta tecnología se encuentra en el desarrollo de tecnologías asistivas, que son dispositivos o sistemas diseñados para mantener o mejorar las capacidades funcionales de personas con discapacidad (Bhute et al., 2021). En este contexto, el HGR con sEMG es fundamental para el control intuitivo de prótesis mioeléctricas (miembros artificiales controlados por las señales eléctricas de los músculos del muñón) (Calado et al., 2024), exoesqueletos de rehabilitación (estructuras robóticas portables que asisten el movimiento durante la terapia) (Tigrini et al., 2023) e interfaces para comunicación alternativa (sistemas que permiten a personas con severas discapacidades motoras comunicarse mediante comandos musculares) (Lehmler et al., 2022).

A pesar de su potencial, uno de los principales desafíos para su aplicación práctica es la variabilidad intrapersonal. Las señales musculares de un mismo individuo pueden modificarse a lo largo del tiempo debido a factores como la fatiga muscular, los cambios en la colocación de los electrodos al poner o quitar el dispositivo, o las adaptaciones fisiológicas propias del día a día (Jie et al., 2021). Esta variabilidad provoca una degradación en el rendimiento de los modelos de clasificación, que ven disminuida su precisión en escenarios de uso prolongado. Para abordar este problema, se desarrollan modelos de inteligencia artificial capaces de aprender patrones complejos a partir de los datos y, potencialmente, adaptarse a estos cambios (Sutrisno et al., 2025; Lehmler et al., 2022). Sin embargo, la efectividad y, sobre todo, la estabilidad de estos modelos a largo plazo necesitan ser evaluadas rigurosamente para garantizar su viabilidad en entornos reales (Tigrini et al., 2023).

Es en este punto donde los modelos de aprendizaje automático (*Machine Learning*, ML) se presentan como una solución necesaria (Anamika et al., 2020; Lehmler et al., 2022). Frente a la variabilidad y complejidad de las señales biológicas, estos modelos pueden extraer y reconocer patrones que son imperceptibles para el ojo humano o para sistemas basados en reglas fijas (Sutrisno et al., 2025). La literatura científica respalda la necesidad de utilizar ML para construir sistemas HGR que sean robustos, es decir, capaces de mantener un rendimiento estable (como una alta exactitud y precisión) a pesar de las variaciones en las señales de entrada, como las causadas por la variabilidad intrapersonal (Calado et al., 2024). Por ejemplo, estudios de validación de clasificadores (Tigrini et al., 2023; Calado et al., 2024) demuestran que es posible obtener altos niveles de precisión incluso con poblaciones de pacientes (como amputados) y con ventanas de tiempo de señal muy cortas, lo cual es esencial para

un control en tiempo real. Asimismo, el uso de estrategias de selección de características, como las evaluadas por Anamika et al. (2020), permite reducir la redundancia y el ruido, mejorando la capacidad de generalización de los modelos. Por lo tanto, la elección y el estudio de modelos de ML apropiados es un paso crítico para traducir esta tecnología del laboratorio a aplicaciones clínicas y comerciales de largo plazo.

Este Trabajo de Integración Curricular (TIC) se centra en la optimización, el entrenamiento y el análisis longitudinal de tres modelos tradicionales de aprendizaje automático. La selección de estos modelos se basa en el equilibrio que ofrecen entre su eficacia (alto poder de clasificación, como lo demuestran estudios como los de Sutrisno et al., 2025; Tigrini et al., 2023; y Calado et al., 2024) y su eficiencia computacional (menor costo de procesamiento y tiempos de entrenamiento más rápidos en comparación con arquitecturas de Deep Learning más complejas) (Calado et al., 2024). Esta característica los hace particularmente atractivos para su implementación en dispositivos con recursos limitados, como las prótesis o sistemas embebidos. Los modelos seleccionados son:

- **k-Nearest Neighbors (kNN)**: clasificador basado en la similitud entre instancias, que asigna una muestra a la clase más frecuente entre sus k vecinos más cercanos. Su simplicidad y capacidad de adaptación a nuevos datos lo hacen adecuado para sistemas que requieren actualizaciones rápidas (Sutrisno et al., 2025).
- **Support Vector Machine (SVM)**: algoritmo que construye un hiperplano óptimo de separación entre clases, maximizando el margen. Su versatilidad mediante el uso de *kernels* permite modelar relaciones no lineales en los datos, lo que ha demostrado un excelente desempeño en la clasificación de señales biomédicas (Tigrini et al., 2023).
- **Artificial Neural Network (ANN)**: red neuronal artificial de propagación hacia adelante capaz de aprender representaciones jerárquicas de los datos. Aunque requiere un mayor costo computacional para su entrenamiento, su capacidad de generalización ha sido ampliamente validada en problemas de reconocimiento de patrones (Calado et al., 2024).

Diversos estudios han demostrado la efectividad de estos modelos en el reconocimiento de gestos a partir de señales sEMG, especialmente cuando se combinan con estrategias adecuadas de extracción y selección de características (Anamika et al., 2020; Lehmler et al., 2022). Por ello, este componente se propone emplear estos tres algoritmos para crear un sistema de reconocimiento de cinco gestos específicos de la mano (*wave in*, *wave out*, *fist*, *open* y *pinch*). Utilizando señales sEMG preprocesadas de siete sesiones mensuales (mes base + seis meses de seguimiento), se realizará un análisis profundo y sistemático de su capacidad para mantener un rendimiento estable a lo largo del tiempo, determinando así su viabilidad en aplicaciones de largo plazo.

III. OBJETIVOS

Objetivo General

Optimizar tres modelos tradicionales de aprendizaje automático (kNN, SVM, ANN) para el reconocimiento de gestos de la mano basado en señales sEMG mediante el análisis de su desempeño a lo largo de siete sesiones mensuales con el fin de evaluar el impacto de la variabilidad intrapersonal en su rendimiento.

Objetivos Específicos

- Estudiar y seleccionar las arquitecturas base para los modelos kNN, SVM y ANN fundamentados en la literatura científica sobre procesamiento de señales biomédicas.
- Entrenar y optimizar los modelos mediante técnicas de búsqueda en grilla y validación cruzada para maximizar la exactitud en el reconocimiento de los cinco gestos de la mano propuestos.
- Comparar y evaluar el rendimiento de los modelos a través de métricas como exactitud, precisión y sensibilidad para determinar su robustez ante la variabilidad temporal en entornos multitemporales.

IV. ALCANCE DEL COMPONENTE

El presente componente se enmarca en un estudio longitudinal que abarca siete sesiones de adquisición de señales sEMG distribuidas mensualmente. Su alcance se estructura en tres fases metodológicas, inspiradas en los procedimientos experimentales reportados en la literatura para la evaluación de clasificadores en entornos multitemporales (Tigrini et al., 2023; Calado et al., 2024), y alineadas con los objetivos específicos planteados:

a) Fase de estudio y selección de arquitecturas

Se realizará una revisión bibliográfica exhaustiva y focalizada en los modelos kNN, SVM y ANN aplicados al reconocimiento de gestos con sEMG, con especial atención a estudios que aborden la variabilidad temporal. A partir de esta revisión, se definirán las arquitecturas base de cada modelo, incluyendo la naturaleza de sus hiperparámetros fundamentales (por ejemplo, el número de vecinos k y el tipo de distancia para kNN; el tipo de kernel y los parámetros C y γ para SVM; el número de capas, neuronas y funciones de activación para ANN). Asimismo, se establecerán las métricas de evaluación y el protocolo experimental que garanticen la reproducibilidad de los resultados.

b) Fase de entrenamiento y optimización

Se implementarán los tres modelos en Python utilizando bibliotecas especializadas (*scikit-learn* para kNN y SVM, *TensorFlow/Keras* para ANN). Para cada modelo se llevará a cabo una búsqueda sistemática de hiperparámetros (por ejemplo: *grid search* o *random search*) con validación cruzada, empleando los datos de la sesión base (mes 0). Se identificarán y registrarán las configuraciones de hiperparámetros que maximicen la exactitud de clasificación en los datos de validación, junto con las métricas asociadas (exactitud, precisión, sensibilidad, F1-score) para cada configuración evaluada. Adicionalmente, se documentará el código y se establecerán mecanismos de automatización para garantizar la reproducibilidad de los experimentos en las sesiones sucesivas.

c) Fase de comparación y evaluación longitudinal

Los modelos optimizados se evaluarán en cada una de las siete sesiones mensuales (mes 0 a mes 6). Para cada sesión se calcularán las métricas de clasificación (exactitud, precisión, sensibilidad, especificidad, F1-score) y se construirán matrices de confusión. Se generarán gráficas de evolución temporal (por ejemplo, exactitud vs. tiempo) que permitan visualizar las tendencias de rendimiento de cada modelo. Para complementar el análisis visual, se aplicará un análisis estadístico descriptivo que incluirá el cálculo de la media y desviación estándar de las métricas por sesión, así como la identificación de tendencias centrales y de variabilidad. Adicionalmente, se emplearán pruebas estadísticas no paramétricas (como la prueba de Friedman o Wilcoxon) para determinar si las diferencias observadas en el rendimiento entre sesiones y entre modelos son estadísticamente significativas. Finalmente, se comparará la estabilidad de los tres enfoques, determinando cuál presenta menor degradación de su rendimiento a lo largo del tiempo y, por lo tanto, mayor capacidad para mantener su precisión ante la variabilidad intrapersonal.

V. TAREAS ESPECÍFICAS

Semana referencial / Etapas	Fecha inicio-fin (si aplica)	Tareas específicas	Resultado esperado (si aplica)
1	06/04/2026 - 10/04/2026	Revisión bibliográfica focalizada en modelos tradicionales de ML (kNN, SVM, ANN) aplicados a HGR con sEMG, con énfasis en estudios longitudinales.	Resumen de 15-20 artículos científicos clave sobre modelos tradicionales en HGR y análisis de variabilidad temporal.
2	13/04/2026 - 17/04/2026	Identificación y definición de métricas de evaluación (exactitud, precisión, sensibilidad, especificidad, F1-score) y protocolo experimental.	Documento con definición formal de métricas y protocolo de evaluación longitudinal.
3	20/04/2026 - 24/04/2026	Diseño de arquitectura del modelo kNN: definición de espacios de hiperparámetros (k, métricas de distancia, ponderación) y estrategia de validación.	Documento técnico con arquitectura kNN y rangos de hiperparámetros a explorar.
4	27/04/2026 - 01/05/2026	Implementación del modelo kNN en Python utilizando scikit-learn. Optimización de hiperparámetros mediante grid search con validación cruzada.	Código funcional de kNN con hiperparámetros optimizados y registro de resultados de validación cruzada.
5	04/05/2026 - 08/05/2026	Diseño de arquitectura del modelo SVM: selección de kernels (lineal, RBF, polinomial), definición de	Documento técnico con arquitectura SVM y configuración de kernels y parámetros candidatos.

		parámetros C y gamma, estrategia de optimización.	
6	11/05/2026 - 15/05/2026	Implementación del modelo SVM en Python. Optimización de hiperparámetros (kernel, C, gamma) mediante búsqueda sistemática.	Código funcional de SVM optimizado con reporte de configuración óptima y métricas de validación.
7	18/05/2026 - 22/05/2026	Diseño de arquitectura del modelo ANN: definición de número de capas ocultas, neuronas por capa, funciones de activación, tasa de aprendizaje.	Documento técnico con arquitectura ANN y especificación de hiperparámetros de red neuronal.
8	25/05/2026 - 29/05/2026	Implementación del modelo ANN utilizando TensorFlow/Keras. Entrenamiento con diferentes configuraciones de arquitectura y regularización.	Código funcional de ANN con historial de entrenamiento, curvas de aprendizaje y modelo optimizado.
9	01/06/2026 - 05/06/2026	Evaluación inicial de los tres modelos (kNN, SVM, ANN) en datos de sesión base (mes 0). Cálculo de métricas de clasificación.	Reporte con resultados iniciales: exactitud, precisión, sensibilidad, especificidad y matrices de confusión para mes 0.
10	08/06/2026 - 12/06/2026	Evaluación de modelos en sesiones mes 1 y mes 2. Registro sistemático de métricas y análisis preliminar de variación temporal.	Tablas de resultados para mes 1 y 2, con comparación inicial respecto a mes 0.
11	15/06/2026 - 19/06/2026	Evaluación de modelos en sesiones mes 3 y mes 4. Análisis de tendencias de degradación o estabilidad.	Tablas de resultados para mes 3 y 4, con análisis de tendencias temporales.
12	22/06/2026 - 26/06/2026	Evaluación de modelos en sesiones mes 5 y mes 6. Completar matriz de resultados longitudinales para las siete sesiones.	Conjunto completo de tablas de resultados para todas las sesiones (mes 0-6).
13	29/06/2026 - 03/07/2026	Análisis comparativo entre los tres modelos (kNN, SVM, ANN). Identificación de modelo más robusto ante variabilidad temporal.	Reporte comparativo con gráficas de evolución temporal y análisis estadístico descriptivo.
14	06/07/2026 - 10/07/2026	Generación de visualizaciones finales (gráficas de exactitud vs tiempo, matrices de confusión agregadas, comparativas de métricas).	Conjunto de gráficas y visualizaciones profesionales listas para inclusión en informe.
15	13/07/2026 - 17/07/2026	Redacción del informe final del Componente A: introducción, metodología, resultados, análisis y conclusiones.	Borrador completo del informe del Componente A para revisión del tutor.
16	20/07/2026 - 24/07/2026	Revisión del informe por parte del tutor. Incorporación de correcciones y ajustes de formato, redacción y contenido técnico.	Listado de comentarios del tutor y versión revisada del informe.

VI. BIBLIOGRAFÍA

- *Barona-Lopez, L. I., Valdivieso-Caraguay, A. L., Benalcazar, M. E., Aguas, X., & Zea, J. A. (2021). Feature Evaluation of EMG Signals for Hand Gesture Recognition Based on Mutual Information, Fuzzy Entropy and RES Index. Communications in Computer and Information Science, 102-119.*
- *Jie, J., Liu, K., Zheng, H., Wang, B., & Dai, R. (2021). High dimensional feature data reduction of multichannel sEMG for gesture recognition based on double phases PSO. Complex & Intelligent Systems, 1-17.*
- *Sutrisno, H., Lu, Y.-C., & Yang, C.-L. (2025). Pattern Grouping-Based Data Analysis Framework for Hand Gesture Recognition. In 2025 The 8th International Conference on Software Engineering and Information Management (ICSIM 2025). ACM.*
- *Calado, A., Roselli, P., Gruppioni, E., Marinelli, A., Bellingegni, A. D., Boccardo, N., & Saggio, G. (2024). A geometric algebra-based approach for myoelectric pattern recognition control and faster prosthesis recalibration. Expert Systems with Applications, 254, 124373.*

- *Anamika, Gupta, R., & Singh, G. (2020). Binary Differential Evolution-Based Feature Selection for Hand Gesture Classification. Lecture Notes in Electrical Engineering, 221-231.*
- *Tigrini, A., Al-Timemy, A. H., Verdini, F., Fioretti, S., Morettini, M., Burattini, L., & Mengarelli, A. (2023). Decoding transient sEMG data for intent motion recognition in transhumeral amputees. Biomedical Signal Processing and Control, 85, 104936.*
- *Lehmler, S. J., Saif-ur-Rehman, M., Glasmachers, T., & Iossifidis, I. (2022). Deep Transfer-Learning for patient specific model re-calibration: Application to sEMG-Classification. arXiv preprint.*
- *Bhute, A., Patil, R. S., Sanghai, S., Yadav, P., & Sathe, S. (2021). Functional Electrical Stimulation for Hand Movement of Person. Lecture Notes in Networks and Systems, 465-481.*

VII. FIRMAS DE RESPONSABILIDAD	
Desarrollado por:	Álvarez Zambrano Alejandro Sebastián
Aprobado por:	Dr. Ángel Leonardo Valdivieso Caraguay Director del Trabajo de Integración Curricular